

MBA⁺

**Artificial Intelligence &
Machine Learning**





Transferlearning

TransferLearning



Transfer Learning é o processo de aproveitar uma rede treinada para um dada tarefa em uma outra tarefa similar

TransferLearning



Imagine que você precisa treinar uma rede para detectar gatos. Infelizmente, você tem **poucas imagens** de gatos e sabe que treinar uma rede do zero não vai funcionar muito bem. Porém, você conhece **uma rede muito boa para detectar cachorros**. Então, você pensa: "Ora, cachorros e gatos são bem parecidos — ambos tem 4 patas, rabo, focinho, pêlos, etc... Então, eu acho que eu posso aproveitar de alguma forma essa rede treinada com cachorros para achar meus gatos também!".

TransferLearning



E isso, meus amigos, é exatamente o que a transferência de aprendizado faz!



Transfer Learning




Traditional ML


vs

Transfer Learning

- Isolated, single task learning:
 - Knowledge is not retained or accumulated. Learning is performed w.o. considering past learned knowledge in other tasks



- Learning of a new tasks relies on the previous learned tasks:
 - Learning process can be faster, more accurate and/or need less training data



TransferLearning




- Os dados usados no treinamento de um classificador devem ser escolhidos de modo a serem representativos;
- **Se não?** A precisão será pior do que o esperado;
- Mas suponha que queremos aplicar um classificador a um novo problema ou mudando de domínio? **Refazer!?**
 - Mas isso é caro.
 - Podemos de alguma forma usar nosso classificador existente como um ponto de partida para nos dar um atalho?

TransferLearning



- Suposições para classificadores:
 - Treinamento e teste são da mesma distribuição;
 - Treinamento e teste estão no mesmo espaço de recurso.




TransferLearning



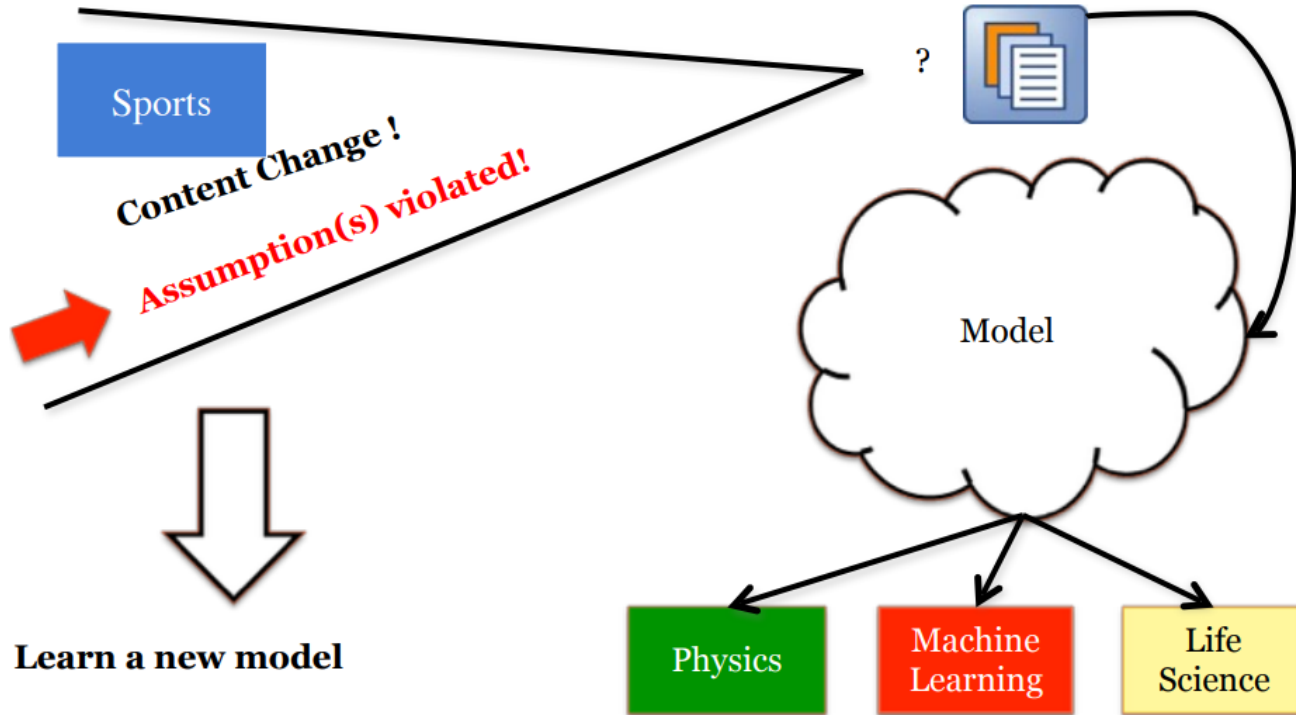
Many security applications, e.g. for access control, use face recognition as one of its components. That is, given the photo (or video recording) of a person, recognize who this person is. In other words, the system needs to **classify** the faces into one of many categories (Alice, Bob, Charlie, ...) or decide that it is an unknown face. A similar, yet conceptually quite different problem is that of verification. Here the goal is to verify whether the person in question is who he claims to be. Note that differently to before, this is now a yes/no question. To deal with different lighting conditions, facial expressions, whether a person is wearing glasses, hairstyle, etc., it is desirable to have a system which *learns* which features are relevant for identifying a person.

Quantum Interpretation: Let us change the way of looking at this problem and thereby turn it into a quantum mechanical experiment. You have heard at various points in your physics course that light comes in little quanta known as photons. The first time this assumption had been made was by Planck in 1900 'as an act of desperation' to be

Darwin gathered data and honed his theory for 20 years before publishing his well-known book in 1859, *The Origin of Species by Means of Natural Selection, or The Preservation of Favoured Races in the Struggle for Life*. Darwin and his fellow naturalist Alfred Wallace independently came to the **conclusion** that **geologically older species** of life **gave rise** to **geologically younger** and different **species** through the process of natural selection.



Transfer Learning




TransferLearning

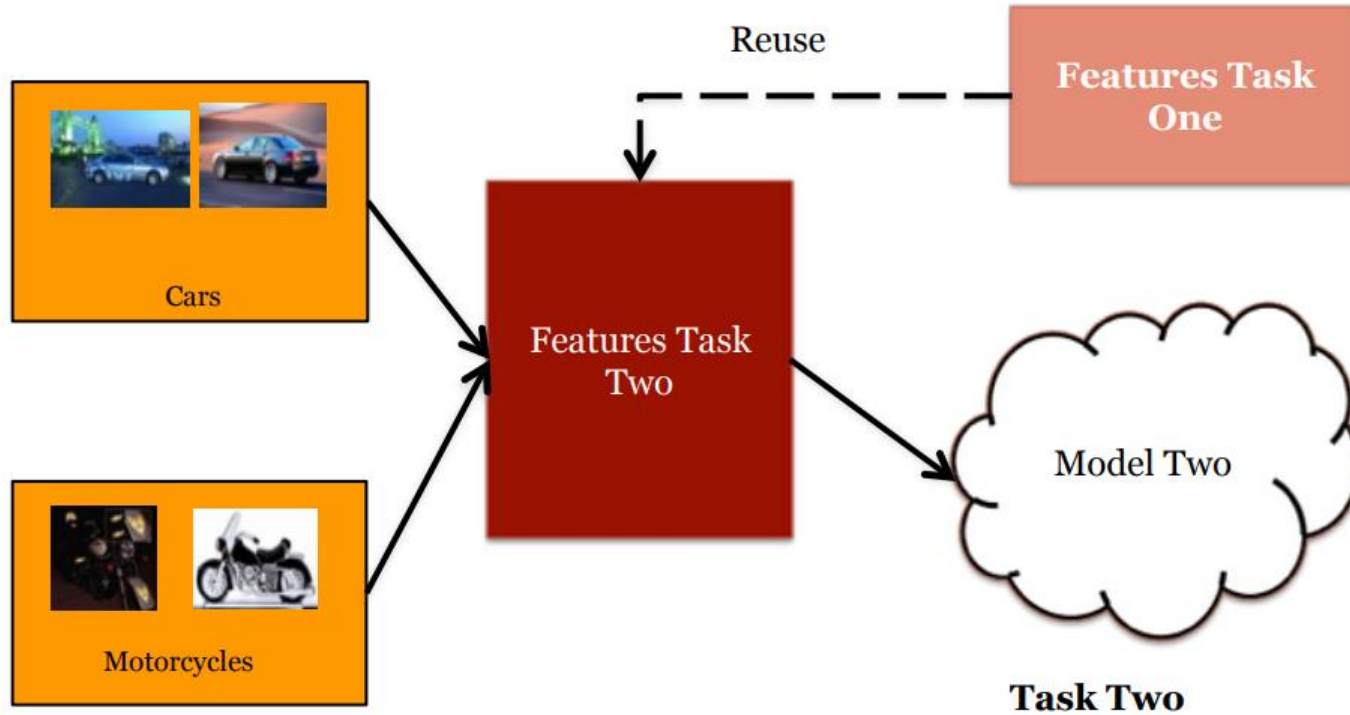


- Duas possíveis violações:
 - Mesma distribuição?
 - Exemplo 1: Diferentes proporções de física, aprendizado de máquina, ciências da vida?
 - Exemplo 2: Diferentes proporções de diabéticos quando comparada a população para a representação em base.
- Mesmo espaço de recurso / tarefa
 - Páginas de esportes: vocabulário diferente, características de BOW mudam
- Retreinar?
 - Experiência pode ser lenta e dolorosa ...
 - Podemos de alguma forma reutilizar e **adaptar o que temos?**

TransferLearning



Transfer Learning



TransferLearning



Classificação de Câncer

$P_S(X)$



Age Smoking

$$\mathcal{X}_S = \{x_1^S, x_2^S\}$$



$$\mathcal{X}_S \neq \mathcal{X}_T$$

$$P_S(X) \neq P_T(X)$$

$P_T(X)$



Age Height Smoking

$$\mathcal{X}_T = \{x_1^T, x_2^T, x_3^T\}$$

TransferLearning



Classificação de Câncer

$P_S(X)$



$$\mathcal{X}_S = \{x_1^S, x_2^S\}$$

Tarefa de Origem:
Classificar em cancer / não
câncer



$$\mathcal{Y}_S \neq \mathcal{Y}_T$$

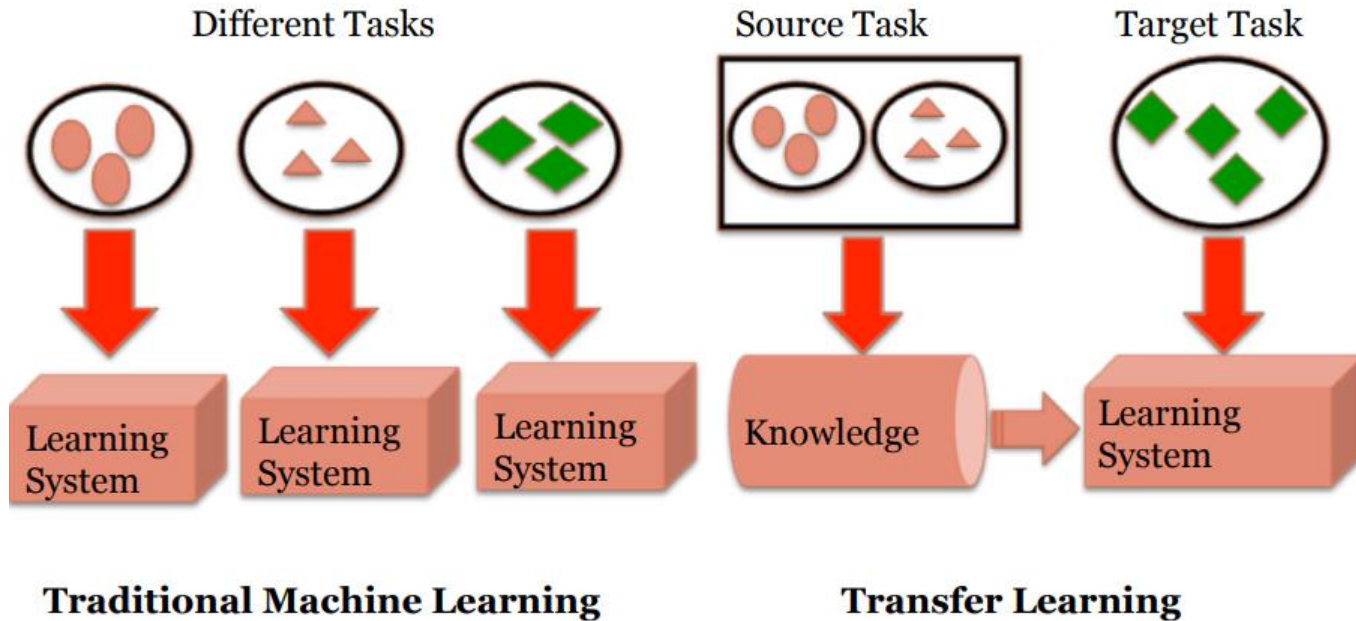
$P_T(X)$



$$\mathcal{X}_T = \{x_1^T, x_2^T, x_3^T\}$$

Tarefa Alvo: Classificar
em cancer de níveis 1, 2 e 3

Transfer Learning



TransferLearning



- Dado um domínio de origem e tarefa de aprendizado de origem, um domínio de destino e uma tarefa de aprendizado de destino, transferência de aprendizagem visa ajudar a melhorar a aprendizagem do alvo via função preditiva usando o conhecimento de origem, onde:
- O domínio de origem não é igual ao domínio de destino:

$$\mathcal{D}_s \neq \mathcal{D}_T$$

- A tarefa de origem não é igual à tarefa de destino:

$$\mathcal{T}_s \neq \mathcal{T}_T$$

TransferLearning



- Diferenças de domínio:

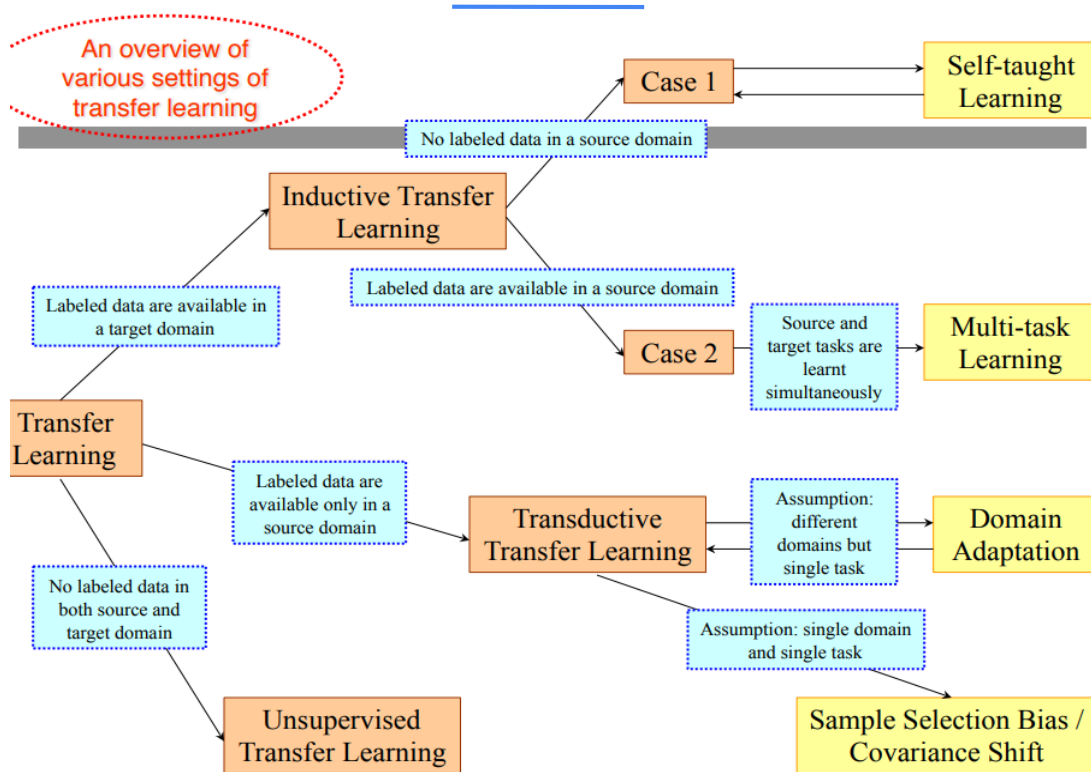
$$\mathcal{X}_S \neq \mathcal{X}_T \quad \mathcal{P}_S(X) \neq \mathcal{P}_T(X)$$

- Diferenças de tarefas:

$$\mathcal{Y}_S \neq \mathcal{Y}_T \quad P(Y_S|X_S) \neq P(Y_T|X_T)$$

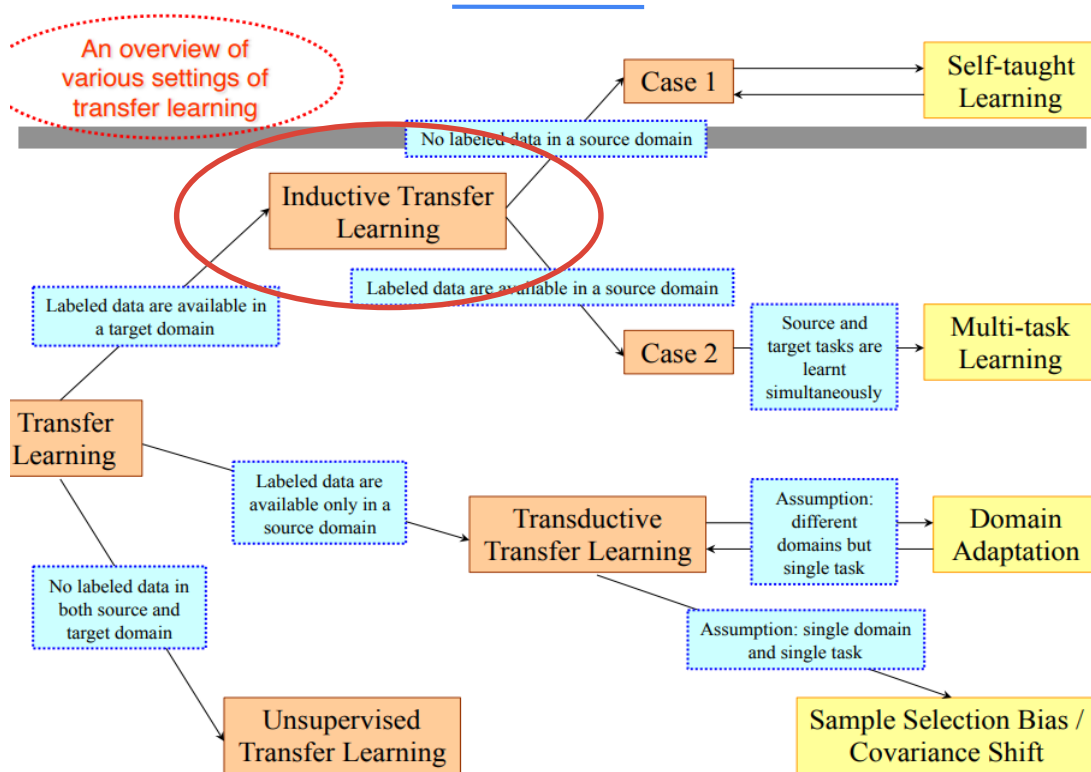


Transfer Learning





Transfer Learning



TransferLearning

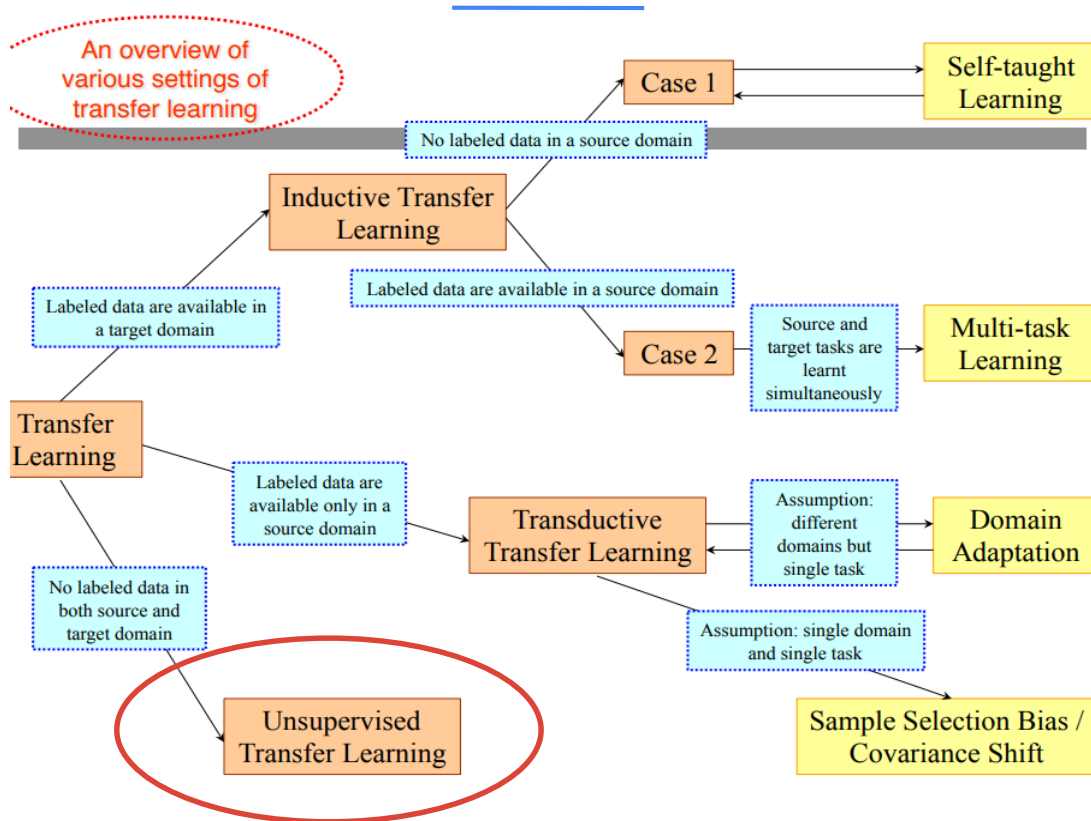


Inductive Transfer learning

Nesse cenário, os domínios de origem e destino são os mesmos, mas as tarefas de origem e destino são diferentes entre si. Os algoritmos tentam utilizar os vieses indutivos do domínio de origem para ajudar a melhorar a tarefa de destino. Dependendo se o domínio de origem contém dados rotulados ou não, isso pode ser dividido em duas subcategorias, semelhantes ao aprendizado multitarefa e aprendizado autodidata, respectivamente.



Transfer Learning



TransferLearning

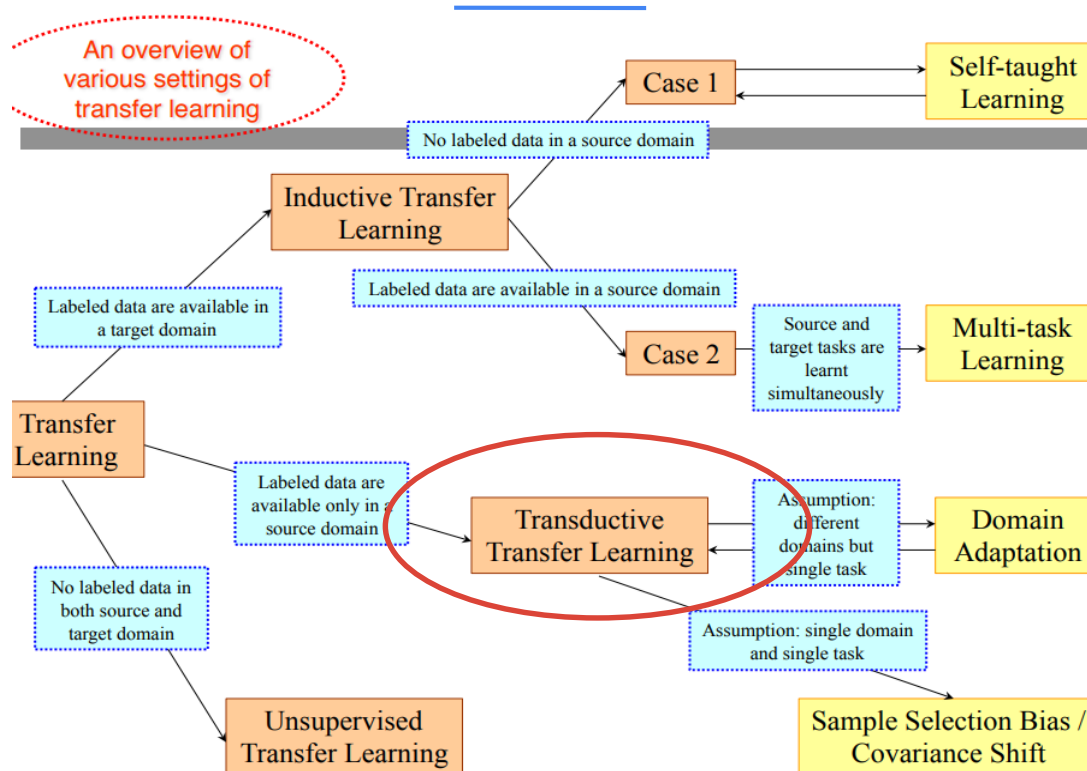


Unsupervised Transfer Learning

Essa configuração é semelhante à própria transferência indutiva, com foco em tarefas não supervisionadas no domínio de destino. Os domínios de origem e de destino são semelhantes, mas as tarefas são diferentes. Nesse cenário, os dados rotulados não estão disponíveis em nenhum dos domínios.



Transfer Learning



TransferLearning



Transductive Transfer Learning

Nesse cenário, há semelhanças entre as tarefas de origem e de destino, mas os domínios correspondentes são diferentes. Nessa configuração, o domínio de origem possui muitos dados rotulados, enquanto o domínio de destino não possui. Isso pode ser classificado ainda mais em subcategorias, referindo-se a configurações nas quais os espaços de recursos são diferentes ou as probabilidades marginais.

TransferLearning



Instance transfer

Reutilizar o conhecimento do domínio de origem para a tarefa de destino geralmente é um cenário ideal. Na maioria dos casos, os dados do domínio de origem não podem ser reutilizados diretamente. Em vez disso, existem determinadas instâncias do domínio de origem que podem ser reutilizadas junto com os dados de destino para melhorar os resultados. No caso de transferência indutiva, modificações como o AdaBoost da Dai e seus co-autores ajudam a utilizar instâncias de treinamento do domínio de origem para melhorias na tarefa de destino.

TransferLearning



Feature-representation transfer

Essa abordagem visa minimizar a divergência de domínio e reduzir as taxas de erro, identificando boas representações de recursos que podem ser utilizadas da origem para os domínios de destino. Dependendo da disponibilidade dos dados rotulados, métodos supervisionados ou não supervisionados podem ser aplicados para transferências baseadas em representação de recursos.

TransferLearning



Parameter transfer

Essa abordagem trabalha no pressuposto de que os modelos para tarefas relacionadas compartilham alguns parâmetros ou distribuição anterior de hiperparâmetros. Diferentemente do aprendizado multitarefa, onde as tarefas de origem e de destino são aprendidas simultaneamente, para transferir o aprendizado, podemos aplicar um peso adicional à perda do domínio de destino para melhorar o desempenho geral.

TransferLearning

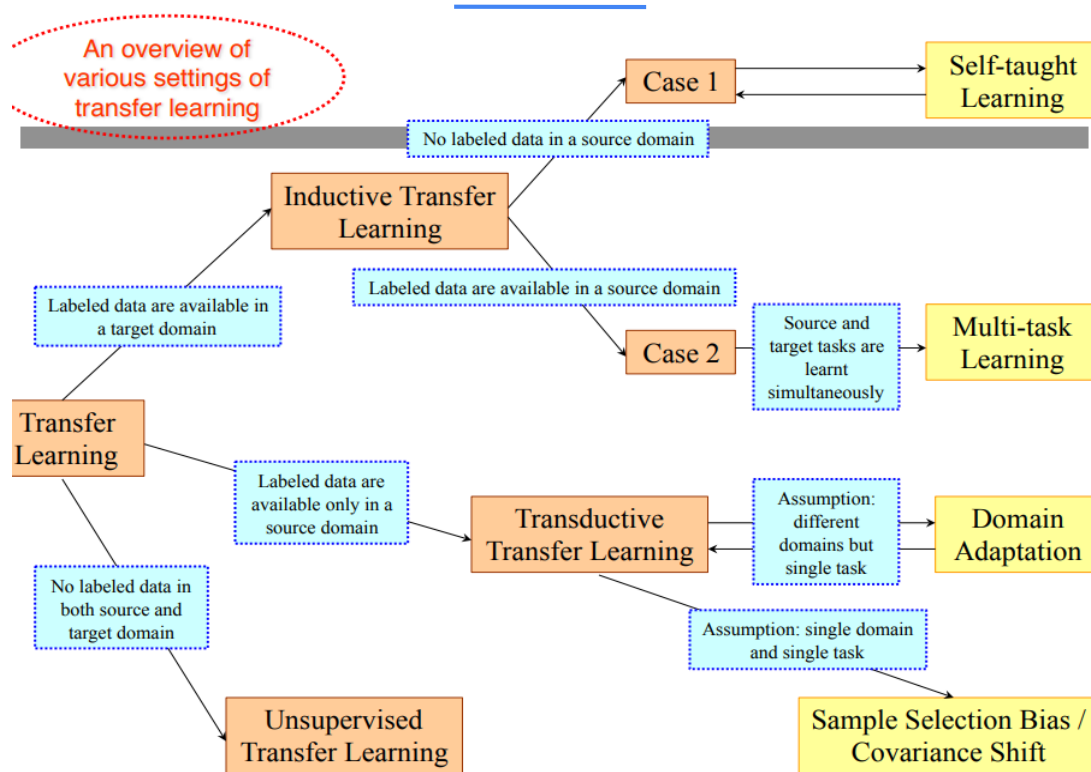


Relational-knowledge transfer

Diferentemente das três abordagens anteriores, a transferência de conhecimento relacional tenta manipular dados, como dados que não são independentes e distribuídos de forma idêntica. Em outras palavras, dados, em que cada ponto de dados tem um relacionamento com outros pontos de dados; por exemplo, dados de redes sociais utilizam técnicas de transferência de conhecimento relacional.



Transfer Learning



TransferLearning



- Idéia:
- Recarregar iterativamente amostras de fontes de forma que:
 - Se reduza o efeito de instâncias de origem "ruins";
 - Se incentivar o efeito de instâncias de origem "boas".
- Requer:
 - Conjunto de dados rotulados da tarefa de origem;
 - Conjunto de dados rotulados de tarefas de destino muito pequeno;
 - Conjunto de dados de destino não rotulados;
 - "Base learner".

Transfer Learning



- Idéia:
- Recarregar iterativamente amostras de fontes de forma que:
 - Se reduza o efeito de instâncias de origem "ruins",
 - Se incentivar o efeito de instâncias de origem "boas".
- Requer:
 - Conjunto de dados rotulados da tarefa de origem;
 - Conjunto de dados rotulados de tarefas de destino muito pequeno;
 - Conjunto de dados de destino não rotulados;
 - "Base learner".

Boosting

Conclusões



- O que transferir
 - Instâncias? Modelos? Características?
- Como transferir
 - Instâncias de peso;
 - Unificação de recursos;
 - Mapeamento de modelos.
- Quando transferir e em quais situações?
 - Mais rápido transferir ou retreinar?

Conclusões



- Objetivo do aprendizado de transferência:
 - Reutilizar o conhecimento aprendido anteriormente para ajudar a desenvolver um novo modelo de aprendizagem.
- Um novo “*base learner*” (mecanismo de aprendizagem) pode ser necessário para:
 - Novas instâncias;
 - Características diferentes;
 - Distribuição diferente dos mesmos recursos.
- Uma nova tarefa:
 - Com algumas semelhanças com a tarefa existente.

Conclusões



- Podemos transferir conhecimento de:
 - Instâncias;
 - Características;
 - Modelo.
- Nem sempre vale a pena se transferir. Ainda deve haver alguma relação entre o conhecimento por trás dos dois mecanismos de aprendizagem.
- Campo complexo e crescente.

Questions and Feedback



[Thank you!](#)

Obrigado !



Vinicius Fernandes Caridá
vfcarida@gmail.com



@Vinicius Caridá



@Vinicius Caridá
@machine learning Brasil



@vfcarida

MBA⁺

Copyright © 2018 **Prof. Vinicius Fernandes Caridá**
 Todos direitos reservados. Reprodução ou divulgação
 total ou parcial deste documento é expressamente
 proibido sem o consentimento formal, por escrito, do
 Professor (autor).